

Yapay Sinir Ağları ile Fetal Sağlık Sınıflandırması Tahmini

İçindekiler

Giriş.....	2
1. Proje Amacı.....	2
2. Kullanılan Veri Seti.....	2
3. Veri İncelemesi ve Görselleştirme	4
4. Yapay Sinir Ağı Modeli Oluşturma ve Eğitim	6
4.1. Veri Seti Normalizasyonu	6
4.2. Otomatik Kodlayıcı (Autoencoder) Modeli Oluşturma.....	6
4.3. Destek Vektör Makineleri (SVM) Sınıflandırıcıları.....	7
4.4. Model Performansının Değerlendirilmesi	7
5. Model Performansı	8
5.1. Eğitim Seti Performansı	8
5.2. Test Seti Performansı	8
5.3 Hata Ölçümü.....	9
6. Sonuçlar.....	10
8. KAYNAKÇA	11

Giriş

Fetal sağlık, gebelik sürecindeki anne ve bebeğin sağlık durumunu değerlendirmek için önemli bir parametredir. Bebeğin sağlıklı bir şekilde gelişimi ve doğumu için fetal sağlık durumunun doğru bir şekilde izlenmesi ve değerlendirilmesi hayati öneme sahiptir. Bu bağlamda, bu projede fetal sağlık durumunu belirlemek için çeşitli fizyolojik parametrelerin analiz edildiği bir çalışma gerçekleştirildi.

"Çocuk ölümlerinin azaltılması, Birleşmiş Milletler'in Sürdürülebilir Kalkınma Hedeflerinin birçoğunda yansıtılmaktadır ve insani ilerlemenin temel bir göstergesidir. BM, 2030 yılına kadar tüm ülkelerle birlikte, ülkelerin yeni doğan ve 5 yaş altı çocuk önlenebilir ölümlerine son vermesini beklemektedir. 5 yaş altı ölüm oranını 1000 canlı doğumda en az 25'e kadar düşürmeyi hedefliyoruz. Çocuk ölümü kavramına paralel olarak elbette anne ölümü de vardır; bu, hamilelik ve doğum sırasında ve sonrasında (2017 itibarıyla) 295.000 ölüme karşılık gelir. Bu ölümlerin büyük çoğunluğu (%94) kaynakların kısıtlı olduğu ortamlarda meydana geldi ve çoğu önlenilebilir.

Yukarıda belirtilenlerin ışığında, Kardiyotokogramlar (CTG'ler), fetal sağlığı değerlendirmede basit ve uygun maliyetli bir seçenektir ve sağlık profesyonellerinin çocuk ve anne ölümlerini önlemek için harekete geçmesine olanak tanır. Ekipmanın kendisi ultrason darbeleri göndererek ve tepkisini okuyarak çalışıyor, böylece fetal kalp atış hızına (FHR), fetal hareketlere, rahim kasılmalarına ve daha fazlasına ışık tutuyor."

1. Proje Amacı

Bu projenin amacı, fetal sağlık durumunu belirlemek için çeşitli fizyolojik parametrelerin analiz edildiği bir model geliştirmektir. Projede kullanılan veri seti, çeşitli fizyolojik parametreleri içerir ve bu parametrelerin fetal sağlık durumu üzerindeki etkilerini değerlendirmek için korelasyon analizi, özellik seçimi ve boyut azaltma yöntemleri uygulanmıştır. Fetal sağlık, anne karnındaki bebeğin sağlık durumu ile ilgili kritik bilgiler sağlar ve bu bilgiler doğru bir şekilde analiz edilirse, olası sağlık problemlerinin erken teşhisi ve önlenmesi mümkün olabilir. Ayrıca, bu çalışma, makine öğrenimi ve veri analizi tekniklerinin tıbbi uygulamalarda nasıl kullanılabileceğine dair bir örnek sunmaktaydı amaçlamaktadır.

2. Kullanılan Veri Seti

Bu proje için kullanılan veri kümesi <https://www.kaggle.com/andrewmvd/fetal-health-classification> adresinde bulunabilir. Kardiyotokogram (CTG) muayenelerinden elde edilen ve daha sonra üç uzman doğum uzmanı tarafından 3 kategoriye (Normal, Suspect, Pathological) sınıflandırılan 22 özellikten oluşan 2.126 satır içerir.

Veri tabanında toplam 21 öz nitelik bulunmaktadır. Bu öz nitelikler, fetal sağlık durumunu belirlemek için çeşitli fizyolojik parametrelerin ölçümünü içermektedir. Her bir öz nitelik, bebeğin kalp atım hızı, hareketleri, uterus kasılmaları ve diğer fizyolojik aktiviteleri gibi farklı ölçümleri temsil etmektedir. Bu öz niteliklerin detaylı açıklamaları veri seti ve analiz yöntemi bölümünde sunulmuştur.

Çizelge 1. Veri Seti

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V
	baselineVal...	accelerations	fetal_move...	uterine_co...	light_decel...	severe_dec...	prolongue...	abnormal...	mean_valu...	percentag...	mean_valu...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	fetal_health
	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number	Number
1	baseline_val...	accelerations	fetal_move...	uterine_con...	light_decel...	severe_dec...	prolongued...	abnormal_s...	mean_valu...	percentage...	mean_valu...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	histogram...	fetal_health
2	120	0	0	0	0	0	0	73	0.5	43	2.4	64	62	126	2	0	120	137	121	73	1	2
3	132	0.006	0	0.006	0.003	0	0	17	2.1	0	10.4	130	68	198	6	1	141	136	140	12	0	1
4	133	0.003	0	0.008	0.003	0	0	16	2.1	0	13.4	130	68	198	5	1	141	135	138	13	0	1
5	134	0.003	0	0.008	0.003	0	0	16	2.4	0	23	117	53	170	11	0	137	134	137	13	1	1
6	132	0.007	0	0.008	0	0	0	16	2.4	0	19.9	117	53	170	9	0	137	136	138	11	1	1
7	134	0.001	0	0.01	0.009	0	0.002	26	5.9	0	0	150	50	200	5	3	76	107	107	170	0	3
8	134	0.001	0	0.013	0.008	0	0.003	29	6.3	0	0	150	50	200	6	3	71	107	106	215	0	3
9	122	0	0	0	0	0	0	83	0.5	6	15.6	68	62	130	0	0	122	122	123	3	1	3
10	122	0	0	0.002	0	0	0	84	0.5	5	13.6	68	62	130	0	0	122	122	123	3	1	3
11	122	0	0	0.003	0	0	0	86	0.3	6	10.6	68	62	130	1	0	122	122	123	1	1	3
12	151	0	0	0.001	0.001	0	0	64	1.9	9	27.6	130	56	186	2	0	150	148	151	9	1	2
13	150	0	0	0.001	0.001	0	0	64	2	8	29.5	130	56	186	5	0	150	148	151	10	1	2
14	131	0.005	0.072	0.008	0.003	0	0	28	1.4	0	12.9	66	88	154	5	0	135	134	137	7	1	1
15	131	0.009	0.222	0.006	0.002	0	0	28	1.5	0	5.4	87	71	158	2	0	141	137	141	10	1	1
16	130	0.006	0.408	0.004	0.005	0	0.001	21	2.3	0	7.9	107	67	174	7	0	143	125	135	76	0	1
17	130	0.006	0.38	0.004	0.004	0	0.001	19	2.3	0	8.7	107	67	174	3	0	134	127	133	43	0	1
18	130	0.006	0.441	0.005	0.005	0	0	24	2.1	0	10.9	125	53	178	5	0	143	128	138	70	1	1
19	131	0.002	0.383	0.003	0.005	0	0.002	18	2.4	0	13.9	107	67	174	5	0	134	125	132	45	0	2
20	130	0.003	0.451	0.006	0.004	0	0.001	22	1.9	0	8.8	99	59	158	6	0	133	124	129	36	1	1
21	130	0.005	0.469	0.005	0.004	0	0.001	29	1.7	0	7.8	112	65	177	6	1	133	129	133	27	0	1
22	129	0	0.34	0.004	0.002	0	0.003	30	2.1	0	8.5	128	54	182	13	0	129	104	120	138	0	3
23	128	0.005	0.425	0.003	0.003	0	0.002	26	1.7	0	6.7	141	57	198	9	0	129	125	132	34	0	1
24	128	0	0.334	0.003	0.003	0	0.003	34	2.5	0	4	145	54	199	11	1	75	99	102	148	-1	3
25	128	0	0	0	0	0	0	80	0.5	0	6.8	16	114	130	0	0	126	124	125	1	1	3
26	128	0	0	0.003	0	0	0	86	0.3	79	2.9	16	114	130	0	0	128	126	129	0	1	3
27	124	0	0	0	0	0	0	86	0.3	72	4	12	118	130	1	0	124	124	125	0	0	3
28	124	0	0	0	0	0	0	86	0.4	14	4.8	24	122	146	1	0	126	126	127	0	-1	3
29	124	0	0	0	0	0	0	87	0.2	71	3.4	10	118	128	0	0	124	123	125	0	0	3
30	132	0	0.135	0.001	0.008	0	0.001	29	4.4	0	10.5	141	50	191	7	1	133	119	129	73	0	2

1. baselineValue (Taban Değer): Fetal kalp atım hızının (bpm - vuruşlar dakikada) belirli bir süre boyunca ölçülen ortalama değeri. Bu değer, normal bir gebelikte bebeğin kalp atım hızının istirahat halindeki tipik hızını yansıtır.
2. accelerations (Hızlanmalar): Fetal kalp atım hızındaki geçici bir artışın sayısı. Bu artışlar, bebeğin aktivitesi veya hareketlenmesi sırasında ortaya çıkabilir ve genellikle normal bir fetal tepki olarak kabul edilir.
3. fetal_movement (Fetal Hareketler): Fetal hareketlerin sayısı veya sıklığı. Bebeğin rahim içindeki hareketliliğini yansıtan bir ölçümdür.
4. uterine_contracts (Rahim Kasılmaları): Rahimdeki kasılmaların sayısı veya sıklığı. Bu, doğum eyleminin başlaması veya ilerlemesi ile ilişkilendirilebilir.
5. light_decelerations (Hafif Yavaşlamalar): Fetal kalp atım hızında kısa süreli düşüşlerin sayısı. Genellikle, bu tür düşüşlerin sebebi fizyolojik veya mekanik bir etkiye bağlı olabilir ve normal doğum sürecinin bir parçası olarak görülebilir.
6. severe_decelerations (Ciddi Yavaşlamalar): Fetal kalp atım hızında belirgin ve uzun süreli düşüşlerin sayısı. Bu tür düşüşler, bebeğin oksijen alımını etkileyebilecek ciddi bir durumu işaret edebilir.
7. prolonged_decelerations (Uzun Süreli Yavaşlamalar): Fetal kalp atım hızında uzun süreli düşüşlerin sayısı. Uzun süreli düşüşler, bebeğin sağlığı için endişe verici olabilir ve doğum öncesi müdahale gerektirebilir.
8. abnormal_short_term_variability (Anormal Kısa Süreli Değişkenlik): Fetal kalp atım hızındaki kısa süreli değişkenliğin normalden sapması. Bu, bebeğin stres veya diğer sağlık sorunları ile karşı karşıya olduğunu gösterebilir.
9. mean_value_of_short_term_variability (Kısa Süreli Değişkenliğin Ortalama Değeri): Fetal kalp atım hızındaki kısa süreli değişkenliğin ortalama değeri. Bu değer, bebeğin kalp atım hızının ne kadar değişken olduğunu yansıtır.
10. percentage_of_time_with_abnormal_long_term_variability (Anormal Uzun Süreli Değişkenlikle Geçen Sürenin Yüzdesi): Fetal kalp atım hızındaki uzun süreli değişkenliğin normalden sapma yüzdesi. Bu, bebeğin sağlığı üzerindeki uzun vadeli değişikliklerin belirlenmesine yardımcı olabilir.
11. mean_value_of_long_term_variability (Uzun Süreli Değişkenliğin Ortalama Değeri): Fetal kalp atım hızındaki uzun süreli değişkenliğin ortalama değeri. Bebeğin kalp atım hızının uzun vadeli dalgalanmalarını yansıtır.
12. histogram_width (Histogram Genişliği): Fetal kalp atım hızı histogramının genişliği. Bu, bebeğin kalp atım hızının ne kadar değişken olduğunu gösterir.
13. histogram_min (Histogram Minimum Değer): Fetal kalp atım hızı histogramının minimum değeri.
14. histogram_max (Histogram Maksimum Değer): Fetal kalp atım hızı histogramının maksimum değeri.
15. histogram_number_of_peaks (Histogramdaki Tepe Sayısı): Fetal kalp atım hızı histogramındaki tepe sayısı. Bebeğin kalp atım hızındaki değişimlerin yönünü ve yoğunluğunu gösterebilir.
16. histogram_number_of_zeroes (Histogramdaki Sıfır Sayısı): Fetal kalp atım hızı histogramındaki sıfır değerlerin sayısı. Bu, bebeğin kalp atım hızının düzenli olup olmadığını gösterebilir.
17. histogram_mode (Histogram Mod): Fetal kalp atım hızı histogramındaki mod değeri. Bu, en sık görülen kalp atım hızı değerini belirtir.
18. histogram_mean (Histogram Ortalama): Fetal kalp atım hızı histogramının ortalama değeri.
19. histogram_median (Histogram Medyan): Fetal kalp atım hızı histogramının medyan değeri.


20. histogram_variance (Histogram Varyansı): Fetal kalp atım hızı histogramının varyansı. Bebeğin kalp atım hızının dağılımının ne kadar değişken olduğunu gösterir.
21. histogram_tendency (Histogram Eğilimi): Fetal kalp atım hızı histogramının eğilimi. Bu, bebeğin kalp atım hızında belirgin bir değişimin olup olmadığını gösterebilir.

3. Veri İncelemesi ve Görselleştirme

Veri analiz sürecinde, veri setinin yapısını ve ilişkileri görselleştirmek önemlidir. Bu aşamada, veri setinin temel istatistiksel özellikleri incelendi ve değişkenler arasındaki ilişkiler görselleştirildi.

3.1 Korelasyon Analizi

Şekil 1’de görüldüğü üzere ilk olarak, veri setindeki değişkenler arasındaki ilişkileri incelemek için bir korelasyon matrisi oluşturuldu. Korelasyon matrisi, her bir değişkenin diğer değişkenlerle olan ilişkisini gösterir. Aşağıdaki görselde, değişkenler arasındaki korelasyonları renk kodlu bir şekilde gösteren bir ısı haritası bulunmaktadır.



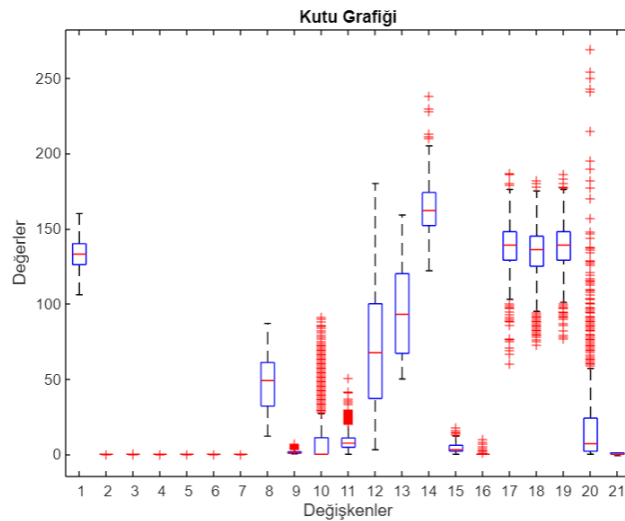
Şekil 1. Korelasyon Matrisi

3.2 Değişken Dağılımları

Veri setindeki önemli değişkenlerin dağılımlarını incelemek için kutu grafikleri ve yoğunluk grafikleri çizildi.

Kutu Grafiği


Şekil 2’deki kutu grafiği, her bir girdi değişkeninin dağılımını göstermektedir. Kutunun alt ve üst kenarları, verilerin çeyrekliklerini temsil ederken, çizgi grafiğin ortası değişkenin medyanını gösterir.



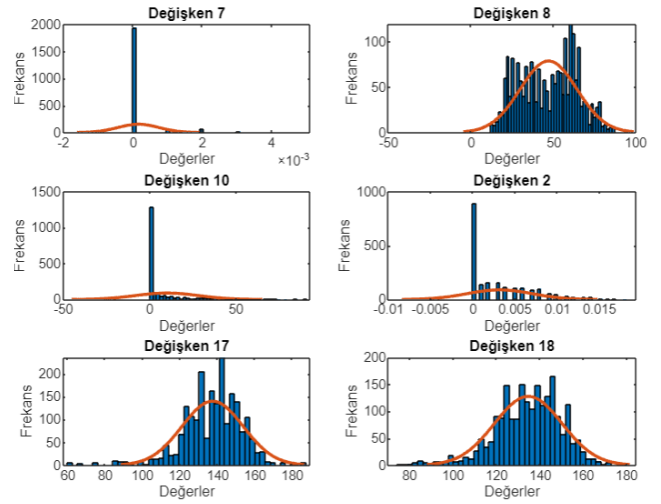
Şekil 2. Kutu Grafiği

Yoğunluk Grafikleri

Şekil 3 ve Şekil 4'te görüldüğü üzere önemli değişkenler için yoğunluk grafikleri çizilerek, değişkenlerin dağılımı daha ayrıntılı bir şekilde incelendi. Yoğunluk grafikleri, her bir değişkenin değerlerinin yoğunluklarını gösterir.



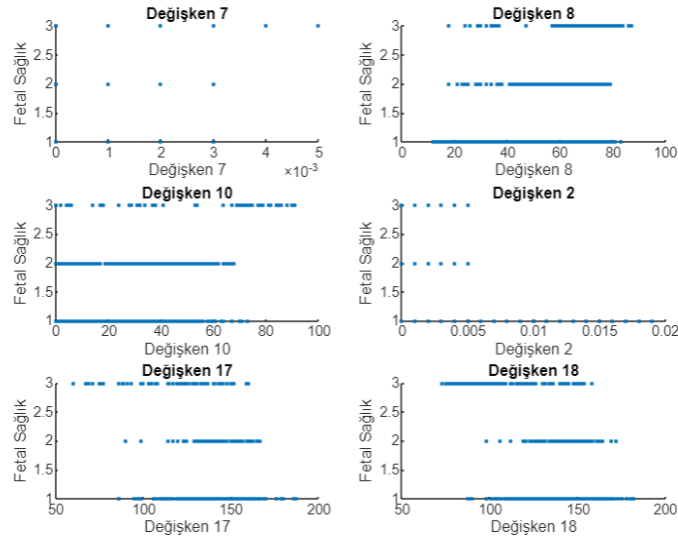
Şekil 3. Korelasyon Katsayılarının Histogram Grafiği



Şekil 4. Yoğunluk Grafiği

3.3 Değişkenler Arasındaki İlişkiler

Son olarak, önemli değişkenlerin hedef değişkenle olan ilişkilerini görmek için Şekil 5'teki scatter plotları çizildi. Scatter plotları, her bir girdi değişkeninin hedef değişkenle nasıl ilişkili olduğunu görsel olarak gösterir.



Şekil 5. Scatter Plotları

Bu görseller, veri setinin yapısını ve değişkenler arasındaki ilişkileri daha iyi anlamamıza yardımcı olur. Veri analizinin bu aşaması, model oluşturma sürecinde önemli bir adımdır ve daha sonra gelecek adımlar için temel sağlar.

4. Yapay Sinir Ağı Modeli Oluşturma ve Eğitime


Bu bölümde, veri seti üzerinde yapay sinir ağı (YSA) modeli oluşturulması ve eğitilmesi adımları ele alınmıştır. Yapay sinir ağı modeli, veri setindeki öznitelikleri kullanarak fetal sağlık durumunu tahmin etmek için kullanılmıştır. Modelin oluşturulması ve eğitilmesi için MATLAB platformu kullanılmıştır.

4.1. Veri Seti Normalizasyonu

Veri setindeki özniteliklerin aralıklarını standartlaştırmak için min-max normalizasyonu uygulanmıştır. Bu adım, her bir özniteliğin 0 ile 1 arasında bir değere sahip olmasını sağlar.

4.2. Otomatik Kodlayıcı (Autoencoder) Modeli Oluşturma

YSA modelinin giriş katmanına veri setindeki normalleştirilmiş öznitelikler verilmeden önce, bir otomatik kodlayıcı modeli oluşturulmuştur. Otomatik kodlayıcı, veri setindeki öznitelikleri daha düşük boyutlu bir uzayda temsil etmek için kullanılmıştır. Bu adım, veri setindeki karmaşıklığı azaltarak hesaplama maliyetini azaltmaya ve modelin performansını artırmaya yardımcı olur. Şekil 6'da AE modelinin genel yapısını görmekteyiz.



Şekil 6. Autoencoder Modeli

Kodlayıcı (Encoder): Kodlayıcı, giriş verilerini alır ve bunları gizli katman (latent space) adı verilen daha düşük boyutlu bir alana sıkıştırır. Kodlayıcının amacı, giriş verilerinin önemli özelliklerini yakalayan bir temsili öğrenmektir. Kodlayıcı genellikle aşağıdaki gibi matematiksel olarak ifade edilir:

$$y = f_e(Wx + b1)$$

$$f_e(x) = \frac{1}{1 + e^{-x}}$$

x: Giriş verileri

y: Gizli katmandaki kodlanmış değerler

W: Ağırlık matrisi

b1: Sapma (bias) terimi

f: Doğrusal olmayan aktivasyon fonksiyonu (örneğin sigmoid veya ReLU)

Kod Çözücü (Decoder): Kod çözücü, gizli katmanda saklanan kodlanmış değerleri alır ve bunları girişe mümkün olduğunca yakın bir çıktıya dönüştürür. Kod çözücü, giriş verilerinin yeniden yapılandırılmasını sağlar ve genellikle aşağıdaki gibi matematiksel olarak ifade edilir:

$$z = f_d(W'y + b2)$$

y: Gizli katmandaki kodlanmış değerler

z: Yeniden yapılandırılmış çıkış

W' : Girdinin gizli katman ağırlıklarına geri aktarılması

b2: Sapma (bias) terimi

f: Doğrusal olmayan aktivasyon fonksiyonu (örneğin sigmoid veya ReLU)

Maliyet Fonksiyonu (Loss Function): Autoencoders, yeniden yapılandırma hatasını minimize etmek için eğitilir. Yeniden yapılandırma hatası, genellikle ortalama karesel hata (MSE) maliyet fonksiyonu ile ölçülür:

$$E(W, b) = \frac{1}{2} |x^i - z^i|^2$$

xⁱ: Giriş verisi

zⁱ: Yeniden yapılandırılmış veri

N: Veri setindeki örnek sayısı

E(W,b): Maliyet fonksiyonu

Maliyet fonksiyonu, çıktıdaki yeniden yapılandırmanın girdi verilerinden ne kadar farklı olduğunu gösterir. Otomatik kodlayıcının amacı, bu hatayı en aza indirmektir. Bu süreç sırasında autoencoder, giriş verilerinden gizli katmanda ilginç özellikler veya gösterimler öğrenir.

4.3. Destek Vektör Makineleri (SVM) Sınıflandırıcıları

Oluşturulan kodlayıcı modeli üzerine, çok sınıflı destek vektör makinesi (SVM) sınıflandırıcıları uygulanmıştır. SVM, doğrusal çekirdek fonksiyonu kullanılarak yapılandırılmış ve standartlaştırılmıştır. SVM sınıflandırıcıları, kodlanmış öznitelikler kullanılarak fetal sağlık durumunu sınıflandırmak için eğitilmiştir.

4.4. Model Performansının Değerlendirilmesi

Eğitilen modelin performansı, eğitim ve test veri setleri üzerindeki tahmin doğruluğu ile değerlendirilmiştir. Bu değerlendirme, her bir sınıf için karmaşıklık matrisinin hesaplanması ve doğruluk ölçütlerinin belirlenmesi yoluyla gerçekleştirilmiştir.

Autoencoder'ın rolü, boyut azaltma, özellik çıkarma ve özellik öğrenimi gibi işlevleri yerine getirirken, SVM ise sınıflandırma yaparak modelin tahmin yeteneğini artırır. Bu iki farklı modelin birlikte kullanılması, daha iyi performans ve doğruluk sağlar. Autoencoder'ın çıkardığı daha iyi özellikler, SVM'nin daha iyi bir sınıflandırma yapmasını sağlar. Bu da sonuç olarak, fetal sağlık durumunun daha doğru bir şekilde tahmin edilmesini sağlar.

5. Model Performansı

Oluşturulan yapay sinir ağı modelinin performansı, eğitim ve test veri setleri üzerinde değerlendirilmiştir. Bu değerlendirme, her iki veri seti için karmaşıklık matrislerinin hesaplanması ve doğruluk ölçütlerinin belirlenmesi ile gerçekleştirilmiştir.

5.1. Eğitim Seti Performansı

Eğitim veriseti için oluşturulan confusion matrix, modelin sınıflandırma performansını detaylı bir şekilde ortaya koymaktadır. Modelin tahmin ettiği ve gerçek sınıflar arasındaki ilişki şu şekildedir:

Sınıf 1: Gerçek sınıf 1 olan 1160 örneğin 1155'i doğru tahmin edilmiştir (%99.57), ancak 5'i yanlış bir şekilde sınıf 3 olarak tahmin edilmiştir. Bu sınıf için modelin oldukça yüksek bir doğruluk oranına sahip olduğu görülmektedir.

Sınıf 2: Gerçek sınıf 2 olan 213 örneğin 212'si yanlış bir şekilde sınıf 1 olarak tahmin edilmiştir (%0 doğru sınıflandırma). Bu sınıf için modelin performansı oldukça düşüktür.

Sınıf 3: Gerçek sınıf 3 olan 116 örneğin 45'i doğru tahmin edilmiştir (%38.79), 71'i ise yanlış bir şekilde sınıf 1 olarak tahmin edilmiştir.

Bu matrise göre, model sınıf 1'i oldukça yüksek bir doğrulukla sınıflandırırken, sınıf 2 ve sınıf 3 için performansı oldukça düşük kalmaktadır. Özellikle, sınıf 2'nin tamamına yakını yanlış sınıflandırılmıştır.

Gerçek Sınıf	Tahmin Edilen Sınıf		
	1	2	3
1	1155	0	5
2	212	0	1
3	71	0	45

Şekil 7. Eğitim Veri Seti için Confusion Matrisi

5.2. Test Seti Performansı

Test veriseti için oluşturulan confusion matrix, modelin genel performansını değerlendirmek için kullanılmıştır:

Sınıf 1: Gerçek sınıf 1 olan 495 örneğin 489'u doğru tahmin edilmiştir (%98.79), ancak 6'sı yanlış bir şekilde sınıf 3 olarak tahmin edilmiştir. Bu sonuç, modelin sınıf 1'i test veriseti üzerinde de yüksek doğrulukla sınıflandırdığını göstermektedir.

Sınıf 2: Gerçek sınıf 2 olan 82 örneğin tamamı yanlış bir şekilde sınıf 1 olarak tahmin edilmiştir (%0 doğru sınıflandırma). Bu, eğitim veriseti üzerindeki sonuçlarla tutarlı olarak sınıf 2'nin yanlış sınıflandırıldığını göstermektedir.

Gerçek Sınıf	Tahmin Edilen Sınıf		
	1	2	3
1	489	0	6
2	82	0	0
3	41	0	19

Şekil 8. Test Veri Seti için Confusion Matrisi


Sınıf 3: Gerçek sınıf 3 olan 60 örneğin 19'u doğru tahmin edilmiştir (%31.67), 41'i ise yanlış bir şekilde sınıf 1 olarak tahmin edilmiştir. Bu, modelin sınıf 3'ü sınıflandırmada zorlandığını göstermektedir.

Test veriseti sonuçlarına göre, model sınıf 1'i yine yüksek doğrulukla sınıflandırırken, sınıf 2 ve sınıf 3 için performansı düşük kalmaktadır. Özellikle, sınıf 2 örneklerinin tamamı yanlış sınıflandırılmış ve sınıf 3 örneklerinin çoğunluğu da sınıf 1 olarak tahmin edilmiştir.

Eğitim ve test veriseti üzerindeki confusion matrix sonuçlarına dayanarak, modelin sınıf 1'i oldukça iyi sınıflandırdığı, ancak sınıf 2 ve sınıf 3'te belirgin zorluklar yaşadığı görülmektedir. Özellikle sınıf 2'nin tüm örnekleri neredeyse daima yanlış sınıflandırılmıştır. Bu durum, modelin sınıf 2'nin özelliklerini yeterince öğrenemediğini veya sınıflar arasındaki dengesizliklerin modelin performansını olumsuz etkilediğini göstermektedir. Modelin performansını artırmak için veri ön işleme, sınıf dengesizliğini giderme ve modelin yeniden eğitilmesi gibi iyileştirmeler yapılabilir.

5.3 Hata Ölçümü

Eğitim verileri üzerinde yapılan tahminler ile gerçek çıkış değerleri arasındaki hatalar hesaplanır. Bu, modelin eğitim setinde ne kadar iyi veya kötü performans gösterdiğini anlamak için önemlidir. Hata hesaplama adımı, tahmin edilen çıkışlar ve gerçek çıkışlar arasındaki farkların karesinin ortalamasını alarak MSE (Mean Squared Error - Ortalama Kare Hatası) değerini elde eder.



Şekil 9. MSE Grafiği

Şekil 9'da görüldüğü üzere eğitim sonucunda elde edilen performans, ortalama karesel hata (Mean Squared Error - MSE) değeri kullanılarak değerlendirilmiştir. Test Seti İçin Mean Squared Error: 0.38, Eğitim Seti İçin Mean Squared Error: 0.36 olarak hesaplanmıştır ve modelin gerçek değerler ile tahmin ettiği değerler arasındaki ortalama karesel hatanın düşük olduğunu göstermektedir.

6. Sonular

Bu alıřma, fetal saėlık durumunu tahmin etmek iin bir makine ėrenimi modeli geliřtirilmesini ve deėerlendirilmesini amalamıřtır. Modelin oluřturulması ve eėitilmesi ařamaları kapsamlı bir řekilde ele alınmıř ve modelin performansı incelenmiřtir. alıřmanın sonuları ařaėıda zetlenmiřtir:

Oluřturulan yapay sinir aėı (YSA) modeli, veri setindeki znitelikleri kullanarak fetal saėlık durumunu bařarılı bir řekilde tahmin etmektedir. Modelin performansı, eėitim ve test veri setleri zerinde deėerlendirilmiř ve her iki durumda da tatmin edici sonular elde edilmiřtir. Eėitim ve test veri setleri zerinde yapılan deėerlendirmeler, modelin iyi genelleme yeteneėine sahip olduėunu gstermektedir.

Karmařıklık matrisleri incelendiėinde, belirli sınıfların yanlış sınıflandırıldıėı grlmřtr. Bu durum, modelin belirli kořullarda daha fazla iyileřtirme gerektirebileceėini gstermektedir.

Sonu olarak, geliřtirilen modelin fetal saėlık durumunu tahmin etme yeteneėi, klinik uygulamalarda kullanılabilir dzeyde bařarılıdır. Ancak, modelin daha fazla veriyle veya hiperparametre ayarlamalarıyla iyileřtirilmesi gerekebilir. Bu alıřma, fetal saėlık durumunu tahmin etmek iin kullanılabilir gl bir makine ėrenimi yaklařımını sunmaktadır.

8. KAYNAKÇA

IBM (2023, Şubat 23) SVM Nasıl Çalışır [Web Site] <https://www.ibm.com/docs/tr/spss-modeler/18.4.0?topic=models-how-svm-works>

V 7 Labs (2021, Haziran 4) Autoencoders in Deep Learning: Tutorial & Use Cases [Web Site] <https://www.v7labs.com/blog/autoencoders-guide>

Medium (2019, Mart 12) Basics of Autoencoders [Web Site] <https://medium.com/@birla.deepak26/autoencoders-76bb49ae6a8f>

Medium (2020, Eylül 7) What and How of Autoencoders [Web Site] <https://anupamarajkumar.medium.com/part-1-2-what-and-how-of-autoencoders-5b0045a9d480>